

信息论自学讲义

从熵、编码到信道容量与可验证算法

RUCmonk2

2026 年 8 月

如何使用这本讲义

这本讲义面向第一次系统学习信息论、同时希望把知识用于随机算法、数据流 Sketch、AI4Math 与 AI4TCS 的读者。它不要求测度论，默认随机变量取有限字母表；所有对数若无特别说明均以 2 为底，因此信息量单位为 bit。

建议每章按四步学习：

1. 先写出本章要回答的问题，不先背公式；
2. 手算正文中的例子，确认公式中的随机变量和分布；
3. 阅读证明骨架，标出每一步使用的假设；
4. 完成章末验收，再进入下一章。

讲义中的“AI4Math / AI4TCS 连接”主要用于提出可检验问题。除非明确给出定理和假设，否则这些连接不应被当作已有理论结论。

目录

如何使用这本讲义	1
第一章 概率、信息量与熵	5
1.1 这一章回答什么	5
1.2 有限概率空间与随机变量	5
1.3 从意外程度到自信息	6
1.4 熵：平均自信息	6
1.4.1 二元熵函数	6
1.5 熵的基本边界	7
1.6 独立重复与可加性	7
1.7 一个完整数值例子	8
1.8 小结与验收	8
第二章 联合熵、互信息与 KL 散度	9
2.1 联合分布、边缘分布与条件分布	9
2.2 熵的链式法则	9
2.3 KL 散度与 Gibbs 不等式	10
2.3.1 交叉熵	11
2.4 互信息	11
2.5 条件互信息与链式法则	12
2.6 条件化减少熵与数据处理不等式	12
2.7 一个联合分布例子	13
2.8 小结与验收	13
第三章 无失真信源编码：从前缀码到 Huffman	14
3.1 编码问题的完整定义	14
3.2 前缀码与二叉树	14
3.3 Kraft–McMillan 不等式	15

3.4	熵与平均码长的基本界	15
3.5	Huffman 算法	16
3.5.1	为什么贪心是最优的	17
3.6	分块编码与渐近信源编码定理	17
3.6.1	典型集与 AEP	17
3.7	三类结论不要混在一起	18
3.8	小结与验收	18
第四章	离散信道、互信息与容量	19
4.1	离散无记忆信道	19
4.2	码、码率与错误概率	19
4.3	二元对称信道 BSC	20
4.4	信道容量	20
4.5	二元擦除信道 BEC	21
4.6	容量究竟说明什么	21
4.7	带输入成本约束的容量	21
4.8	小结与验收	22
第五章	随机编码与可靠通信	23
5.1	联合典型性	23
5.2	随机码本与典型译码	23
5.3	Union bound 给出的速率条件	24
5.4	为什么随机证明能推出确定码存在	24
5.5	Fano 不等式	25
5.6	信道编码逆定理	25
5.7	存在性、构造性与有限块长	26
5.8	小结与验收	26
第六章	信息论与 Sketch、通信复杂度和 AI4TCS	27
6.1	Sketch 是受限长度的消息	27
6.2	从熵界到通信下界的基本骨架	27
6.3	预测作为 side information	28
6.4	Consistency 与 robustness	28
6.5	Verifier 反馈包含多少信息	29
6.6	证明轨迹、程序与描述长度	29
6.7	适合当前背景的研究问题	29

6.8 证据等级表	30
6.9 小结与验收	30
第七章 综合习题与参考答案	31
7.1 习题	31
7.2 参考答案与提示	32

第一章 概率、信息量与熵

1.1 这一章回答什么

信息论首先要回答一个看似简单的问题：一个随机结果出现时，我们“获得了多少信息”？回答这个问题前，必须先把随机对象、分布和平均方式写清楚。本章集中处理单个离散随机变量，目标是建立后续所有公式的共同语言。

1.2 有限概率空间与随机变量

设样本空间为有限集合 Ω ，概率函数 $\mathbb{P}$ 满足

$$\mathbb{P}(\omega) \geq 0, \quad \sum_{\omega \in \Omega} \mathbb{P}(\omega) = 1.$$

随机变量 $X : \Omega \rightarrow \mathcal{X}$ 把基本结果映射到字母表 $\mathcal{X}$ 。它的概率质量函数为

$$p_X(x) = \mathbb{P}[X = x].$$

对任意函数 f ，期望定义为

$$\mathbb{E}[f(X)] = \sum_{x \in \mathcal{X}} p_X(x) f(x).$$

方差衡量围绕均值的平方波动：

$$\text{Var}(X) = \mathbb{E}[(X - \mathbb{E}X)^2] = \mathbb{E}[X^2] - (\mathbb{E}X)^2.$$

例 1.1 (Bernoulli 随机变量). 若 $X \sim \text{Bernoulli}(p)$ ，则

$$\mathbb{P}[X = 1] = p, \quad \mathbb{P}[X = 0] = 1 - p,$$

并且 $\mathbb{E}X = p$ 、 $\text{Var}(X) = p(1-p)$ 。同一个取值 $X = 1$ 在不同 p 下有不同的意外程度；信息量因此必须依赖分布，而不能只依赖符号本身。

1.3 从意外程度到自信息

如果事件发生概率为 p ，希望它的信息量 $i(p)$ 满足：

1. 概率越小，信息量越大；
2. 必然事件的信息量为 0；
3. 独立事件同时发生时，信息量相加，即 $i(pq) = i(p) + i(q)$ ；
4. $i(p)$ 随 p 连续变化。

这些条件把函数确定为对数形式。

定义 1.2 (自信息). 事件 $X = x$ 的自信息定义为

$$i_X(x) = -\log_2 p_X(x).$$

当 $p_X(x) = 0$ 时，该取值不会被实际观测；求和中采用约定 $0 \log 0 = 0$ 。

若 $p_X(x) = 1/2$ ，观测它得到 1 bit；若概率为 $1/8$ ，得到 3 bits。这里的 bit 是信息单位，不是变量在计算机中实际占用的位数。

容易混淆

自信息描述“在给定分布模型下，一个结果有多意外”。它不等于语义重要性。一个极小概率的乱码可能有很高自信息，但对研究问题没有任何价值。

1.4 熵：平均自信息

定义 1.3 (Shannon 熵). 离散随机变量 X 的熵为

$$H(X) = \mathbb{E}[i_X(X)] = -\sum_{x \in \mathcal{X}} p_X(x) \log_2 p_X(x).$$

熵是分布 p_X 的函数。它对符号名字不敏感，只关心各概率的排列。

1.4.1 二元熵函数

对 $X \sim \text{Bernoulli}(p)$ ，定义

$$h_2(p) = -p \log_2 p - (1-p) \log_2 (1-p).$$

它满足 $h_2(0) = h_2(1) = 0$ 、 $h_2(1/2) = 1$ ，并关于 $p = 1/2$ 对称。

对 $0 < p < 1$ 求导：

$$h'_2(p) = \log_2 \frac{1-p}{p}, \quad h''_2(p) = -\frac{1}{\ln 2} \left(\frac{1}{p} + \frac{1}{1-p} \right) < 0.$$

因此二元熵严格凹，并在 $p = 1/2$ 取得最大值。

例 1.4 (偏斜硬币). 若 $p = 1/4$ ，则

$$h_2(1/4) = -\frac{1}{4} \log_2 \frac{1}{4} - \frac{3}{4} \log_2 \frac{3}{4} \approx 0.811 \text{ bits}.$$

它小于公平硬币的 1 bit，因为偏斜硬币更容易预测。

1.5 熵的基本边界

定理 1.5 (有限字母表上的熵界). 若 $|\mathcal{X}| = m$ ，则

$$0 \leq H(X) \leq \log_2 m.$$

左侧等号当且仅当 X 几乎必然为某个固定值；右侧等号当且仅当 X 在 $\mathcal{X}$ 上均匀分布。

证明骨架. 每一项 $-p(x) \log p(x)$ 非负，所以 $H(X) \geq 0$ 。上界可以由下一章的 KL 非负性得到。令 U 为 $\mathcal{X}$ 上的均匀分布，则

$$D_{\text{KL}}(P_X \| U) = \sum_x p(x) \log_2 \frac{p(x)}{1/m} = \log_2 m - H(X) \geq 0.$$

等号条件来自 KL 散度为零当且仅当两个分布相同。 □

直觉

熵上界说的是：若只有 m 种可能结果，平均不确定性不会超过区分 m 个等概率结果所需的 $\log_2 m$ bits。它不是说任何单个符号都能用 $\log_2 m$ 个比特无损编码；编码是否为整数长度、是否允许分块，还要在第三章讨论。

1.6 独立重复与可加性

若 $X_1, \dots, X_n$ 相互独立，则联合分布分解为

$$p(x_1, \dots, x_n) = \prod_{i=1}^n p_i(x_i).$$

于是

$$\begin{aligned} H(X_1, \dots, X_n) &= -\mathbb{E} \log_2 \prod_{i=1}^n p_i(X_i) \\ &= \sum_{i=1}^n H(X_i). \end{aligned}$$

对独立同分布样本 $X^n = (X_1, \dots, X_n)$, 有 $H(X^n) = nH(X)$ 。

容易混淆

没有独立性时, 联合熵一般不等于边缘熵之和。正确关系是下一章的链式法则 $H(X, Y) = H(X) + H(Y|X)$ 。

1.7 一个完整数值例子

设字母表为 $\{a, b, c, d\}$, 分布为

$$p = (1/2, 1/4, 1/8, 1/8).$$

四个符号的自信息分别为 1, 2, 3, 3 bits, 因此

$$H(X) = \frac{1}{2} \cdot 1 + \frac{1}{4} \cdot 2 + \frac{1}{8} \cdot 3 + \frac{1}{8} \cdot 3 = 1.75 \text{ bits}.$$

这个例子随后会对应一棵 Huffman 树, 其码长正好为 1, 2, 3, 3, 平均码长等于熵。一般分布不一定恰好达到熵, 只能满足相应上下界。

1.8 小结与验收

本节验收

在不看讲义的情况下完成:

1. 解释自信息和熵分别是“单次量”还是“平均量”;
2. 推导 $h'_2(p)$ 并说明公平硬币为何熵最大;
3. 手算分布 $(1/2, 1/4, 1/8, 1/8)$ 的熵;
4. 说明“熵为 1 bit”为什么不等于每个观测在文件中恰好占 1 bit。

第二章 联合熵、互信息与 KL 散度

上一章只处理一个随机变量。本章研究两个变量之间的信息关系：知道 Y 后， X 还剩多少不确定性？两个变量共享多少统计信息？两个分布相差多少？

2.1 联合分布、边缘分布与条件分布

联合概率质量函数为 $p_{XY}(x, y)$ 。边缘分布由求和得到：

$$p_X(x) = \sum_y p_{XY}(x, y), \quad p_Y(y) = \sum_x p_{XY}(x, y).$$

当 $p_Y(y) > 0$ 时，条件分布为

$$p_{X|Y}(x|y) = \frac{p_{XY}(x, y)}{p_Y(y)}.$$

独立性等价于 $p_{XY}(x, y) = p_X(x)p_Y(y)$ 对所有 (x, y) 成立。

定义 2.1 (联合熵与条件熵).

$$\begin{aligned} H(X, Y) &= - \sum_{x, y} p(x, y) \log_2 p(x, y), \\ H(X|Y) &= \sum_y p(y) H(X|Y = y) \\ &= - \sum_{x, y} p(x, y) \log_2 p(x|y). \end{aligned}$$

2.2 熵的链式法则

定理 2.2 (链式法则).

$$H(X, Y) = H(Y) + H(X|Y) = H(X) + H(Y|X).$$

更一般地，

$$H(X_1, \dots, X_n) = \sum_{i=1}^n H(X_i | X_1, \dots, X_{i-1}).$$

证明. 利用 $p(x, y) = p(y)p(x|y)$, 有

$$\begin{aligned} H(X, Y) &= - \sum_{x, y} p(x, y) \log_2 [p(y)p(x|y)] \\ &= - \sum_{x, y} p(x, y) \log_2 p(y) - \sum_{x, y} p(x, y) \log_2 p(x|y) \\ &= H(Y) + H(X|Y). \end{aligned}$$

交换 X, Y 得到另一种分解。多变量版本反复应用二变量链式法则即可。 $\square$

直觉

联合不确定性可以按顺序支付：先描述 Y ，再在已知 Y 的条件下描述 X 。链式法则是编码、典型集和通信协议中最常用的“信息记账规则”。

2.3 KL 散度与 Gibbs 不等式

定义 2.3 (KL 散度). 对有限集合上的分布 P, Q , 若 $P(x) > 0$ 时均有 $Q(x) > 0$, 定义

$$D_{\text{KL}}(P\|Q) = \sum_x P(x) \log_2 \frac{P(x)}{Q(x)}.$$

若存在 $P(x) > 0$ 但 $Q(x) = 0$, 则散度为 $+\infty$ 。

定理 2.4 (Gibbs 不等式).

$$D_{\text{KL}}(P\|Q) \geq 0,$$

等号当且仅当 $P = Q$ (在 P 的支持上)。

证明. 使用自然对数不等式 $\ln t \leq t - 1$:

$$\begin{aligned} D_{\text{KL}}(P\|Q) &= -\frac{1}{\ln 2} \sum_x P(x) \ln \frac{Q(x)}{P(x)} \\ &\geq -\frac{1}{\ln 2} \sum_x P(x) \left(\frac{Q(x)}{P(x)} - 1 \right) \\ &= -\frac{1}{\ln 2} \left(\sum_x Q(x) - \sum_x P(x) \right) = 0. \end{aligned}$$

等号要求 $Q(x)/P(x) = 1$ 对所有 $P(x) > 0$ 成立。 $\square$

2.3.1 交叉熵

交叉熵定义为

$$H(P, Q) = - \sum_x P(x) \log_2 Q(x).$$

它满足

$$H(P, Q) = H(P) + D_{\text{KL}}(P \| Q).$$

当真实分布固定时，最小化交叉熵等价于最小化 $D_{\text{KL}}(P \| Q)$ 。这解释了分类模型中的交叉熵目标，但不意味着交叉熵下降自动带来推理、证明或算法能力。

容易混淆

KL 散度不是距离：通常 $D(P \| Q) \neq D(Q \| P)$ ，也不满足三角不等式。书写时不能省略方向。

例 2.5 (KL 的不对称性). 取 $P = (1/2, 1/2)$ 、 $Q = (3/4, 1/4)$ ，则

$$D(P \| Q) = \frac{1}{2} \log_2 \frac{2}{3} + \frac{1}{2} \log_2 2 \approx 0.2075,$$

$$D(Q \| P) = \frac{3}{4} \log_2 \frac{3}{2} + \frac{1}{4} \log_2 \frac{1}{2} \approx 0.1887.$$

两者不同。

2.4 互信息

定义 2.6 (互信息).

$$I(X; Y) = D_{\text{KL}}(P_{XY} \| P_X P_Y) = \sum_{x,y} p(x, y) \log_2 \frac{p(x, y)}{p(x)p(y)}.$$

由 KL 非负性， $I(X; Y) \geq 0$ ；等号当且仅当 X, Y 独立。

把联合分布分解为 $p(x, y) = p(y)p(x|y)$ ，可得四个等价表达：

$$\begin{aligned} I(X; Y) &= H(X) - H(X|Y) \\ &= H(Y) - H(Y|X) \\ &= H(X) + H(Y) - H(X, Y) \\ &= D_{\text{KL}}(P_{XY} \| P_X P_Y). \end{aligned}$$

因此，互信息既可以解释为“观察 Y 后 X 的不确定性平均减少多少”，也可以解释为“联合分布偏离独立分布多远”。

例 2.7 (带噪复制). 设 $X \sim \text{Bernoulli}(1/2)$ ， $N \sim \text{Bernoulli}(q)$ 且独立，令 $Y = X \oplus N$ 。则

Y 仍均匀,

$$H(Y) = 1, \quad H(Y|X) = H(N) = h_2(q),$$

所以

$$I(X;Y) = 1 - h_2(q).$$

当 $q = 0$ 时完全保留 1 bit; 当 $q = 1/2$ 时输出与输入独立, 互信息为 0。

2.5 条件互信息与链式法则

定义 2.8 (条件互信息).

$$I(X;Y|Z) = H(X|Z) - H(X|Y,Z).$$

它是对每个 $Z = z$ 的互信息取平均, 因此非负。互信息链式法则为

$$I(X;Y,Z) = I(X;Z) + I(X;Y|Z).$$

进一步,

$$I(X;Y_1, \dots, Y_n) = \sum_{i=1}^n I(X;Y_i|Y_1, \dots, Y_{i-1}).$$

2.6 条件化减少熵与数据处理不等式

由 $I(X;Y) = H(X) - H(X|Y) \geq 0$, 得到

$$H(X|Y) \leq H(X).$$

这是一条平均意义的结论; 对某个特定 $Y = y$, 条件熵可以高于原熵。

定理 2.9 (数据处理不等式). 若 $X \rightarrow Y \rightarrow Z$ 构成 Markov 链, 即给定 Y 后 Z 与 X 条件独立, 则

$$I(X;Z) \leq I(X;Y).$$

证明骨架. 一方面, 由链式法则

$$I(X;Y,Z) = I(X;Y) + I(X;Z|Y) = I(X;Y),$$

其中 Markov 条件给出 $I(X;Z|Y) = 0$ 。另一方面,

$$I(X;Y,Z) = I(X;Z) + I(X;Y|Z) \geq I(X;Z).$$

合并即得结论。 □

直觉

对数据做后处理不能凭空增加它与原始变量之间的统计信息。后处理可以重新组织、压缩或突出某些信息，但若只观察 $Z = f(Y)$ ，关于 X 的总互信息不会超过观察完整 Y 。

2.7 一个联合分布例子

令联合分布为

	$Y = 0$	$Y = 1$
$X = 0$	3/8	1/8
$X = 1$	1/8	3/8

两个边缘分布都均匀，所以 $H(X) = H(Y) = 1$ 。给定 Y 后， $X = Y$ 的概率为 $3/4$ ，故

$$H(X|Y) = h_2(1/4) \approx 0.811, \quad I(X;Y) \approx 0.189 \text{ bits.}$$

这个数值等于一个交叉概率 $q = 1/4$ 的二元对称信道所保留的信息。

2.8 小结与验收

本节验收

1. 从 $p(x, y) = p(y)p(x|y)$ 推导熵的链式法则；
2. 说明 KL 散度非负的关键不等式和等号条件；
3. 写出互信息的四种等价表达，并解释每一种视角；
4. 对上面的 2×2 联合分布手算 $H(X|Y)$ 和 $I(X;Y)$ ；
5. 用一句话说明数据处理不等式依赖的 Markov 假设。

第三章 无失真信源编码：从前缀码到 Huffman

3.1 编码问题的完整定义

设信源符号 X 取值于有限字母表 $\mathcal{X} = \{x_1, \dots, x_m\}$ ，概率为 $p_i = \mathbb{P}[X = x_i]$ 。二元变长码是映射

$$C : \mathcal{X} \rightarrow \{0, 1\}^*,$$

其中 $\{0, 1\}^*$ 表示所有有限二进制串。记码字长度为 $\ell_i = |C(x_i)|$ ，平均码长为

$$L(C) = \sum_{i=1}^m p_i \ell_i.$$

几个常被混用的概念必须分开：

非奇异 (nonsingular) 不同源符号映到不同码字；

唯一可译 (uniquely decodable) 任意有限源序列连接后的比特串只能被解成唯一源序列；

前缀码 (prefix-free) 没有码字是另一码字的前缀；


瞬时码 (instantaneous) 从左到右读到一个码字结尾时即可立即输出符号，不必等待后续比特。

二元前缀码与瞬时码是同一类。前缀码一定唯一可译，但唯一可译码未必前缀无关；非奇异也远弱于唯一可译。

例 3.1 (非奇异但不可唯一译). 取 $C(a) = 0, C(b) = 01, C(c) = 10$ 。码字互不相同，但串 010 既可译为 ac ，也可译为 ba ，所以不是唯一可译码。

3.2 前缀码与二叉树

把比特 0/1 看成从根节点向左/右走一步。每个码字对应一条根到节点的路径。前缀码要求所有码字都位于叶节点：如果某码字对应内部节点，它就会成为更长码字的前缀。



这棵树对应码字 0, 10, 110, 111, 码长为 1, 2, 3, 3。

3.3 Kraft–McMillan 不等式

定理 3.2 (Kraft 不等式). 若存在码长为 $\ell_1, \dots, \ell_m$ 的二元前缀码, 则

$$\sum_{i=1}^m 2^{-\ell_i} \leq 1.$$

反过来, 只要一组正整数码长满足该不等式, 就存在具有这些码长的二元前缀码。

树的证明. 取 $L = \max_i \ell_i$. 深度为 ℓ_i 的叶节点覆盖深度 L 上的 $2^{L-\ell_i}$ 个后代。前缀无关保证这些后代集合互不相交, 因此

$$\sum_i 2^{L-\ell_i} \leq 2^L.$$

两边除以 2^L 得必要性。充分性可按码长从短到长贪心分配尚未被占用的叶节点；Kraft 和不超过 1 保证每一步都有位置。□

对唯一可译码, 更一般的 McMillan 不等式仍给出同样的必要条件。因此, 在最小化平均码长时, 限制到前缀码不会损失最优值。

直觉

$2^{-\ell_i}$ 可以理解为码字在无限二叉树边界上占据的“份额”。短码字占据更大的子树, 所以不能给太多符号同时分配短码字。

3.4 熵与平均码长的基本界

定理 3.3 (无失真一符号编码界). 对任意唯一可译二元码,

$$L \geq H(X).$$

并且存在前缀码满足

$$H(X) \leq L < H(X) + 1.$$

下界. 令 $K = \sum_i 2^{-\ell_i} \leq 1$, 定义分布

$$q_i = \frac{2^{-\ell_i}}{K}.$$

直接计算可得

$$D_{\text{KL}}(P\|Q) = L - H(X) + \log_2 K.$$

因此

$$L - H(X) = D_{\text{KL}}(P\|Q) - \log_2 K \geq 0.$$

□

上界. 取 Shannon 码长

$$\ell_i = \lceil -\log_2 p_i \rceil.$$

则 $2^{-\ell_i} \leq p_i$, 所以 Kraft 和不超过 1, 存在相应前缀码。同时

$$\ell_i < -\log_2 p_i + 1,$$

对 p_i 加权求和即得 $L < H(X) + 1$ 。

□

容易混淆

$L \geq H(X)$ 是平均码长的结论, 不是说每个符号码长都至少为其自信息, 也不是说任意一个文件都一定能压缩。整数码长造成的一符号冗余可以通过分块编码摊薄。

3.5 Huffman 算法

Huffman 算法在所有二元前缀码中最小化平均码长:

1. 选择概率最小的两个符号;
2. 把它们合并为概率之和的新节点;
3. 在缩小后的字母表上重复;
4. 逆序展开合并树, 左右边分别标 0/1。

例 3.4 (完整 Huffman 计算). 仍取 $p = (1/2, 1/4, 1/8, 1/8)$:

$$1/8 + 1/8 \rightarrow 1/4, \quad 1/4 + 1/4 \rightarrow 1/2, \quad 1/2 + 1/2 \rightarrow 1.$$

得到码长 1, 2, 3, 3, 平均码长

$$L = \frac{1}{2} + \frac{1}{2} + \frac{3}{8} + \frac{3}{8} = 1.75 \text{ bits} = H(X).$$

这里恰好等于熵，是因为所有概率都是 2 的负整数次幂。

3.5.1 为什么贪心是最优的

最优性证明包含两个关键事实：

1. 存在一棵最优前缀树，使概率最小的两个符号位于最深层且互为兄弟；这是通过交换叶节点而不增大平均码长得到的；
2. 把这两个兄弟合并为一个伪符号后，原问题的最优树对应缩小问题的最优树，否则可替换为更优子树并产生矛盾。

这正是贪心选择性质与最优子结构。

若使用最小堆，Huffman 建树时间为 $O(m \log m)$ 。编码和解码时间还取决于消息长度和树/码表表示。

3.6 分块编码与渐近信源编码定理

对独立同分布信源 $X_1, X_2, \dots$ ，把长度 n 的块 X^n 当作一个大符号。直接应用上一节的界：

$$H(X^n) \leq L_n < H(X^n) + 1.$$

因为独立同分布给出 $H(X^n) = nH(X)$ ，故每个源符号的平均码长满足

$$H(X) \leq \frac{L_n}{n} < H(X) + \frac{1}{n}.$$

这说明整数码长造成的每符号冗余可随块长趋于无穷而消失。

3.6.1 典型集与 AEP

定义弱典型集

$$A_\epsilon^{(n)} = \left\{ x^n : \left| -\frac{1}{n} \log_2 p(x^n) - H(X) \right| \leq \epsilon \right\}.$$

渐近等概率性质 (AEP) 说明：对任意 $\epsilon > 0$,

$$\mathbb{P}[X^n \in A_\epsilon^{(n)}] \rightarrow 1.$$

典型序列的概率约为 $2^{-nH(X)}$ ，典型集大小约为 $2^{nH(X)}$ 。更精确地，当 n 足够大时，

$$(1 - \epsilon)2^{n(H - \epsilon)} \leq |A_\epsilon^{(n)}| \leq 2^{n(H + \epsilon)}.$$

定理 3.5 (几乎无失真固定长度信源编码). 对独立同分布有限字母表信源：

- 若码率 $R > H(X)$ ，存在长度 n 的固定长度块码，使错误概率趋于 0；
- 若 $R < H(X)$ ，错误概率不能趋于 0。

可达性骨架. 给每个典型序列分配唯一索引，非典型序列统一报错。典型集大小至多

$$2^{n(H+\epsilon)}.$$

所以当 $R > H + \epsilon$ 时有足够的 2^{nR} 个索引。错误只在非典型事件上发生，其概率趋于 0。□

逆定理直觉. 码率 R 的固定长度码最多区分 2^{nR} 个序列，而高概率质量分散在约 2^{nH} 个典型序列上。若 $R < H$ ，可唯一表示的典型序列只占指数级变小的一部分，无法让错误概率消失。□

3.7 三类结论不要混在一起

情形	是否允许错误	主要对象	结论
一符号变长码	不允许	平均整数码长	$H \leq L < H + 1$
分块变长码	不允许	每符号平均码长	$H \leq L_n/n < H + 1/n$
固定长度块码	允许小错误	码率与错误概率	$R > H$ 可使错误趋零

3.8 小结与验收

本节验收

1. 给出“非奇异、唯一可译、前缀码”的包含关系和一个反例；
2. 用二叉树证明 Kraft 不等式；
3. 对概率 (0.4, 0.3, 0.2, 0.1) 手工运行 Huffman 算法并计算平均码长；
4. 解释 $H \leq L < H + 1$ 中的 1 从哪里来，分块为何能摊薄它；
5. 区分无错变长编码定理与允许小错误的固定长度信源编码定理。

第四章 离散信道、互信息与容量

信源编码问“如何消除冗余”；信道编码问“如何在噪声中可靠通信”。两者使用同一个熵与互信息语言，但优化对象和允许的误差不同。

4.1 离散无记忆信道

定义 4.1 (离散无记忆信道). 输入字母表为 $\mathcal{X}$ 、输出字母表为 $\mathcal{Y}$ 。信道由转移概率

$$W(y|x) = \mathbb{P}[Y = y|X = x]$$

描述，并满足对每个 x 有 $\sum_y W(y|x) = 1$ 。无记忆表示长度 n 使用时

$$W^n(y^n|x^n) = \prod_{i=1}^n W(y_i|x_i).$$

给定输入分布 p_X 后，联合分布为

$$p_{XY}(x, y) = p_X(x)W(y|x),$$

输出分布为 $p_Y(y) = \sum_x p_X(x)W(y|x)$ 。互信息 $I(X; Y)$ 衡量一次信道使用平均保留了多少关于输入的信息。

4.2 码、码率与错误概率

一个 (n, M) 信道码包含：

- 消息 J 在 $\{1, \dots, M\}$ 中取值；
- 编码器 $f: J \mapsto X^n$ ；
- 信道产生 $Y^n \sim W^n(\cdot|X^n)$ ；
- 解码器 $g: Y^n \mapsto \hat{J}$ 。

码率为

$$R = \frac{1}{n} \log_2 M \quad \text{bits/channel use.}$$


平均错误概率为 $P_e = \mathbb{P}[\hat{J} \neq J]$ 。最大错误概率则对最坏消息取最大值；两种口径不能在结果表中混用。

4.3 二元对称信道 BSC

BSC(q) 以概率 q 翻转输入比特：

$$Y = X \oplus Z, \quad Z \sim \text{Bernoulli}(q),$$

且 Z 与 X 独立。



因为给定 X 后 Y 的不确定性只来自噪声，

$$H(Y|X) = H(Z) = h_2(q).$$

所以

$$I(X;Y) = H(Y) - h_2(q).$$

4.4 信道容量

定义 4.2 (容量). 离散无记忆信道的容量定义为

$$C = \max_{p_X} I(X;Y).$$

最大化变量是输入分布，而信道 $W(y|x)$ 固定。

定理 4.3 (BSC 容量). 对 $0 \leq q \leq 1/2$,

$$C_{\text{BSC}(q)} = 1 - h_2(q).$$

均匀输入 $X \sim \text{Bernoulli}(1/2)$ 达到容量。

证明. 由 $I(X;Y) = H(Y) - h_2(q)$ 且二元变量熵至多为 1,

$$I(X;Y) \leq 1 - h_2(q).$$

当输入均匀时, BSC 的对称性使输出也均匀, 故 $H(Y) = 1$, 达到上界。□

边界情况给出直观检查: $q = 0$ 时无噪声, 容量为 1; $q = 1/2$ 时输出独立于输入, 容量为 0。若 $q > 1/2$, 接收端可以统一翻转输出, 把交叉概率降为 $1 - q$ 。

4.5 二元擦除信道 BEC

BEC(ε) 以概率 $1 - \varepsilon$ 正确输出输入比特, 以概率 ε 输出擦除符号 ?。接收端知道哪些位置被擦除。

给定均匀输入, 未擦除时获得 1 bit, 擦除时获得 0 bit, 因此

$$C_{\text{BEC}(\varepsilon)} = 1 - \varepsilon.$$

BEC 与 BSC 的区别在于: 擦除位置可见, 而翻转位置不可见。相同数值的 q 与 ε 不代表相同难度。

4.6 容量究竟说明什么

容量是一个渐近阈值:

- 当 $R < C$, 存在一系列块长增长的码, 使错误概率趋于 0;
- 当 $R > C$, 不可能让错误概率趋于 0。

容量定义本身只给出单字母优化问题。把它解释成可靠通信阈值, 需要下一章的信道编码定理。

容易混淆

容量不等于某个具体码在有限块长上的吞吐量, 也不包含编码/解码计算成本。随机编码证明“存在好码”, 不代表已经给出可高效实现的码。

4.7 带输入成本约束的容量

若输入符号 x 有成本 $c(x)$, 并要求 $\mathbb{E}[c(X)] \leq \Gamma$, 容量变为

$$C(\Gamma) = \max_{p_X: \mathbb{E}c(X) \leq \Gamma} I(X;Y).$$

这提醒我们：优化信息量时必须同时写清资源约束。AI 系统中的 token、查询、编译或 verifier 调用也有成本，但只有在建立了精确随机模型后，才能合法地套用信息论结论。

4.8 小结与验收

本节验收

1. 写出 DMC、 (n, M) 码、码率和平均错误概率的定义；
2. 从 $I(X; Y) = H(Y) - H(Y|X)$ 推导 BSC 容量；
3. 比较 BSC 与 BEC：接收端分别知道什么；
4. 解释容量是渐近存在性阈值，而不是有限长度代码的直接性能；
5. 给一个需要成本约束的现实通信或算法例子。

第五章 随机编码与可靠通信

本章解释信道编码定理的两半：为什么低于容量的速率存在可靠码，以及为什么高于容量不可能可靠通信。核心工具分别是随机码本与典型性、Fano 不等式与数据处理。

5.1 联合典型性

对输入分布 p_X 和信道 $W(y|x)$ ，联合分布为 $p_{XY}(x, y) = p_X(x)W(y|x)$ 。长度 n 的序列对 (x^n, y^n) 若其经验信息量接近相应熵，称为联合典型。

本章只使用联合典型性的三个性质：

1. 若 $X^n \sim p_X^n$ 且 $Y^n \sim W^n(\cdot|X^n)$ ，则 (X^n, Y^n) 以趋于 1 的概率联合典型；
2. 若 $\tilde{X}^n \sim p_X^n$ 与 $Y^n \sim p_Y^n$ 独立，则

$$\mathbb{P}[(\tilde{X}^n, Y^n) \text{ 联合典型}] \lesssim 2^{-n(I(X;Y)-\delta(\epsilon))};$$

3. 典型序列的概率和集合大小都具有指数阶控制。

第二条最关键：一个与输出无关的错误码字，伪装成“与输出匹配”的概率约为 $2^{-nI(X;Y)}$ 。

5.2 随机码本与典型译码

固定输入分布 p_X 和码率 R ，令 $M = 2^{nR}$ 。随机生成码本：对每个消息 $m \in \{1, \dots, M\}$ ，独立采样

$$X^n(m) \sim \prod_{i=1}^n p_X(x_i).$$

发送消息 m 时把 $X^n(m)$ 输入信道。解码器观察 Y^n 后，寻找唯一满足 $(X^n(\hat{m}), Y^n)$ 联合典型的码字；若不存在或不唯一则报错。

由于码本生成和信道都对消息编号对称，可以假设发送消息 1。定义错误事件：

$$\begin{aligned} E_0 &= \{(X^n(1), Y^n) \text{ 不联合典型}\}, \\ E_m &= \{(X^n(m), Y^n) \text{ 联合典型}\}, \quad m \neq 1. \end{aligned}$$

整体错误包含于

$$E_0 \cup \bigcup_{m=2}^M E_m.$$

5.3 Union bound 给出的速率条件

由联合典型性, $\mathbb{P}(E_0) \rightarrow 0$ 。对于每个错误码字, 由于 $X^n(m)$ 与实际输出 Y^n 独立,

$$\mathbb{P}(E_m) \lesssim 2^{-n(I(X;Y)-\delta)}.$$

使用 union bound:

$$\begin{aligned} \mathbb{P}[\text{error}] &\leq \mathbb{P}(E_0) + \sum_{m=2}^M \mathbb{P}(E_m) \\ &\lesssim \mathbb{P}(E_0) + 2^{nR} 2^{-n(I(X;Y)-\delta)} \\ &= \mathbb{P}(E_0) + 2^{-n(I(X;Y)-R-\delta)}. \end{aligned}$$

只要

$$R < I(X;Y) - \delta,$$

平均错误概率就趋于 0。再对输入分布优化, 得到所有 $R < C = \max_{p_X} I(X;Y)$ 都可达。

定理 5.1 (信道编码定理: 可达性). 对离散无记忆信道, 任意 $R < C$ 都存在一列 $(n, 2^{nR})$ 码, 使平均错误概率随 $n \rightarrow \infty$ 趋于 0。

5.4 为什么随机证明能推出确定码存在

上面的错误概率同时对随机码本、随机消息和随机信道噪声取平均。若所有确定码本的错误概率都大于某个数, 随机选择后的平均也会大于该数。反过来, 随机码本平均错误概率很小, 必然至少存在一个确定码本不超过这个平均值。

直觉

随机编码是概率方法: 随机性主要服务于存在性证明。证明结束后, 可以固定一个表现良好的码本。它没有自动告诉我们如何高效找到、存储或解码这个码本。

若要从平均错误转成最大错误, 还需删除错误概率最差的一部分码字 (expurgation) 或使用更细分析。论文中必须明确采用哪种错误口径。

5.5 Fano 不等式

定理 5.2 (Fano 不等式). 设消息 J 取 M 个值, 估计为 $\hat{J}$, 错误概率 $P_e = \mathbb{P}[\hat{J} \neq J]$, 则

$$H(J|\hat{J}) \leq h_2(P_e) + P_e \log_2(M-1) \leq 1 + P_e \log_2 M.$$

证明骨架. 令错误指示变量 $E = \mathbf{1}\{J \neq \hat{J}\}$. 一方面,

$$H(E, J|\hat{J}) = H(J|\hat{J}) + H(E|J, \hat{J}) = H(J|\hat{J}),$$

因为 E 由 $(J, \hat{J})$ 决定. 另一方面,

$$H(E, J|\hat{J}) = H(E|\hat{J}) + H(J|E, \hat{J}).$$

第一项至多 $h_2(P_e)$; 当 $E = 0$ 时 J 已知, 当 $E = 1$ 时至多剩 $M-1$ 种可能, 所以第二项至多 $P_e \log_2(M-1)$. $\square$

Fano 不等式把“低错误率”转换为“小条件熵”: 如果几乎总能从观察中恢复消息, 那么观察后关于消息剩余的不确定性必须很小。

5.6 信道编码逆定理

设消息 J 均匀分布, 因此 $H(J) = \log_2 M = nR$. 编码和信道形成 Markov 链

$$J \rightarrow X^n \rightarrow Y^n \rightarrow \hat{J}.$$

由熵分解与 Fano 不等式:

$$\begin{aligned} nR &= I(J; Y^n) + H(J|Y^n) \\ &\leq I(X^n; Y^n) + 1 + P_e nR. \end{aligned}$$

对无记忆信道, 链式法则和容量定义给出

$$I(X^n; Y^n) \leq \sum_{i=1}^n I(X_i; Y_i) \leq nC.$$

因此

$$R \leq C + \frac{1}{n} + P_e R.$$

若 $P_e \rightarrow 0$ 且 $n \rightarrow \infty$, 必有 $R \leq C$.

定理 5.3 (信道编码定理: 逆定理). 若存在一系列码使错误概率趋于 0, 则其渐近码率不超过容量 C .

5.7 存在性、构造性与有限块长

信道编码定理是渐近结果，不能直接回答有限 n 的工程问题。实际还要考虑：

- 码本构造和存储成本；
- 编码、解码复杂度与延迟；
- 有限块长下的错误概率；
- 平均错误与最大错误；
- 信道模型失配和输入成本约束。

现代编码理论中的线性码、LDPC、polar code 等，正是在可靠性、码率和计算效率之间寻找可构造方案。

容易混淆

“随机搜索找到一个在测试集上正确的程序”和随机编码定理不是同一件事。后者有明确的概率空间、错误事件、指数规模码本和渐近证明；前者若没有隐藏测试、分布假设与理论分析，只是经验结果。

5.8 小结与验收

本节验收

1. 画出随机码本、信道、典型译码的完整流程；
2. 写出 E_0 与 E_m ，说明它们为何具有不同概率界；
3. 从 union bound 推出条件 $R < I(X; Y)$ ；
4. 复述 Fano 不等式证明中错误指示变量的作用；
5. 解释“随机码本平均表现好”为什么能推出至少一个确定码本存在；
6. 列出信道编码定理没有解决的三个有限块长问题。

第六章 信息论与 Sketch、通信复杂度和 AI4TCS

本章不再引入完整新定理，而是把前五章的对象映射到数据流和可验证算法研究中。每个连接都要区分：严格归约、可证明上界、启发式指标和仅用于建立直觉的类比。

6.1 Sketch 是受限长度的消息

数据流算法把长输入流压缩成小状态 S 。若状态使用 s bits，那么它最多有 2^s 种取值。查询算法只能依据 S 和查询参数输出答案。

这与单向通信协议非常接近：

1. Alice 读取流的前一部分并生成 sketch S ；
2. Alice 把 S 作为消息发送给 Bob；
3. Bob 根据自己的输入继续更新或发起查询；
4. 若 sketch 能解决流问题，通信协议就能解决相应通信问题。

因此，如果相关通信问题需要至少 b bits，任何实现该归约的 sketch 也必须使用至少 b bits。

直觉

流式空间下界常问：有限状态究竟区分了多少种输入情况？信息论提供“状态容量”的语言，通信复杂度则提供把空间限制转成消息长度限制的标准模型。

6.2 从熵界到通信下界的基本骨架

设 Alice 的随机输入为 X ，消息为 $M = f(X)$ ，长度至多 s bits，则

$$H(M) \leq s, \quad I(X; M) \leq H(M) \leq s.$$

若任务要求 Bob 从 (M, Y) 中以小错误恢复 X 的某个高信息量函数，就可借助 Fano 不等式或问题特定论证，推出 $I(X; M|Y)$ 必须足够大，进而得到 s 的下界。

真正的下界证明还需要：

- 选择困难输入分布；
- 明确允许的随机性 (public/private coins)；
- 明确单向还是多轮通信；
- 把流算法的成功概率、passes 和空间逐项映射到协议。

6.3 预测作为 side information

在 learning-augmented streaming 中，预测 Z 可以被看作关于真实流特征 X 的 side information。自然问题包括：

$H(X|Z)$ 比 $H(X)$ 小多少？

$I(X; Z) = H(X) - H(X|Z)$ 是否能转化为空间收益？

Slepian–Wolf 理论表明，在特定的独立同分布分布式无失真压缩模型中，解码端拥有 Z 时， X 的渐近压缩率可下降到 $H(X|Z)$ 。但学习增强 Sketch 往往是 worst-case 流、有限内存、在线更新和查询误差模型，不能直接套用该结论。

容易混淆

预测的 KL 误差小，不自动推出某个 sketch 的查询误差小；互信息高，也不自动给出高效在线算法。必须提供把信息量连接到具体状态、更新和查询保证的定理。

6.4 Consistency 与 robustness

学习增强算法通常同时要求：

Consistency 预测准确时优于经典基线；

Robustness 预测任意错误时不会比经典基线坏太多。

一个完整问题必须定义预测接口 Z 、误差度量 $\eta(X, Z)$ 、资源成本和查询误差。例如：

$$\text{space} = S(\epsilon, \delta, \eta), \quad \mathbb{P}[|\hat{f} - f| > E(\eta)] \leq \delta.$$

信息论可以帮助设计 η 或证明不可能性，但最终保证要落到算法参数上。

6.5 Verifier 反馈包含多少信息

在 verifier-guided search 中，候选对象为 C ，反馈为 F 。若 verifier 只返回一位 accept/reject，则单次反馈熵至多 1 bit；若返回详细反例、proof state 或连续分数，理论上可能携带更多关于候选错误结构的信息。

但“反馈字段更多”不等于“搜索有效信息更多”：

- 反馈可能高度冗余；
- 搜索器可能无法利用其结构；
- 反馈可能泄漏 benchmark 答案并导致投机；
- 生成反馈的计算成本可能远高于收益。

可以把研究问题写成：在固定 verifier 成本下，哪种反馈表示提高了候选成功率或降低了搜索样本复杂度？

6.6 证明轨迹、程序与描述长度

证明、程序和算法都可以编码成有限字符串。描述长度可以用来提出问题：

- 一个候选是否只是现有解的冗长等价变换？
- 搜索空间的表示是否引入大量无意义自由度？
- 证明证书能否被短消息验证？

但不能把“描述更短”直接等同于“数学更深”或“算法复杂度更优”。Kolmogorov complexity、最小描述长度和 Shannon 熵属于不同层次的对象，需要各自的模型和假设。

6.7 适合当前背景的研究问题

与 AI4Math / AI4TCS 的连接

一个可控的两周问题可以这样定义：

1. 选择 Count-Min Sketch 作为经典 baseline；
2. 令预测器给出候选 heavy hitters 或频率先验；
3. 明确定义预测误差，而不是只给模型准确率；
4. 比较 exact counter、经典 sketch 和预测增强版本；
5. 记录空间、查询误差、失败概率和最坏预测分布；
6. 只把实验证据写成经验结果，把 consistency/robustness 留给可证明部分。

6.8 证据等级表

证据	可以说明	不能单独说明
有限数据实验	特定分布和预算上的表现	worst-case 或渐近保证
随机测试	抽样范围内未发现错误	任意输入正确
通信归约	模型内的空间/通信下界	其他模型仍然不可能
信息不等式	随机变量间的必然约束	存在高效实现算法
Lean/kernel 检查	当前形式化命题可证明	自然语言语义正确或有创新性

6.9 小结与验收

本节验收

1. 画出一从流算法到单向通信协议的归约流程；
2. 解释消息长度 s 为什么给出 $I(X; M) \leq s$ ；
3. 给出一个 side information 有用但不能直接套 Slepian–Wolf 的流式例子；
4. 为一个 learning-augmented sketch 写出 prediction interface、error、consistency 和 robustness；
5. 区分 verifier 反馈的字段长度、熵和对搜索真正有用的信息。

第七章 综合习题与参考答案

建议先独立完成，再查看参考答案。答案强调关键步骤，不替代完整书写。

7.1 习题

- I1. 计算分布 $(1/2, 1/4, 1/8, 1/8)$ 的熵，并说明为什么它被码长 $(1, 2, 3, 3)$ 精确达到。
- I2. 设 $X \sim \text{Bernoulli}(p)$ 。证明 $h_2(p)$ 关于 $p = 1/2$ 对称且严格凹，并找出最大值。
- I3. 给出一个非奇异但不可唯一译的码，再给出一个唯一可译但非前缀码的码（可查阅 Sardinas-Patterson 判据验证后者）。
- I4. 判断码长集合 $(1, 2, 3, 3)$ 、 $(1, 2, 2, 3)$ 、 $(2, 2, 3, 3, 3)$ 是否满足 Kraft 不等式。
- I5. 对分布 $(0.4, 0.3, 0.2, 0.1)$ 构造 Huffman 码，计算平均码长并与熵比较。
- I6. 设 $Y = X \oplus N$ ，其中 $X \sim \text{Bernoulli}(1/2)$ 、 $N \sim \text{Bernoulli}(q)$ 且独立。计算 $H(Y)$ 、 $H(Y|X)$ 和 $I(X; Y)$ 。
- I7. 证明若 $X \rightarrow Y \rightarrow Z$ 是 Markov 链，则 $I(X; Z) \leq I(X; Y)$ 。
- I8. 解释固定长度信源编码中，为什么 $R > H(X)$ 时典型集可以被索引，而 $R < H(X)$ 时不够。
- I9. 推导 $\text{BEC}(\varepsilon)$ 的容量，并比较它和 $\text{BSC}(\varepsilon)$ 的数值及语义差别。
- I10. 在随机编码证明中，若 $R = I(X; Y) - 2\delta$ ，估计错误码字联合典型事件的 union bound 指数阶。
- I11. 使用 Fano 不等式解释：若从 s -bit 消息中恢复一个均匀 m -bit 字符串且错误概率趋零，为什么必须有 $s \gtrsim m$ 。
- I12. 为“预测增强 Count-Min Sketch”写一份信息论问题定义，至少包含随机变量、预测误差、资源、成功事件和不声称的结论。

7.2 参考答案与提示

I1. 自信息为 1, 2, 3, 3, 所以 $H = 1.75$ bits。概率满足 $p_i = 2^{-\ell_i}$, 且 Kraft 和等于 1, 因此整数码长与理想自信息完全一致。

I2. 直接代换 $1 - p$ 得对称性。二阶导

$$h_2''(p) = -\frac{1}{\ln 2} \left(\frac{1}{p} + \frac{1}{1-p} \right) < 0$$

给出严格凹；一阶导在 $p = 1/2$ 为零，最大值为 1。

I3. 非奇异但不可唯一译可用 $\{0, 01, 10\}$, 因为 010 有两种解析。唯一可译但非前缀码可用 $\{0, 01\}$: 0 是 01 的前缀, 但任何合法串中出现的 1 只能与它前面的 0 组成 01, 因此解析唯一。严格处理更大码集时可使用 Sardinas-Patterson 判据, 不能只凭“短时间没找到歧义”下结论。

I4. 分别计算 Kraft 和:

$$\frac{1}{2} + \frac{1}{4} + \frac{1}{8} + \frac{1}{8} = 1, \quad \frac{1}{2} + \frac{1}{4} + \frac{1}{4} + \frac{1}{8} = \frac{9}{8} > 1, \quad \frac{1}{4} + \frac{1}{4} + 3 \cdot \frac{1}{8} = \frac{7}{8}.$$

第一、第三组可构造前缀码, 第二组不行。

I5. 合并 $0.1 + 0.2 = 0.3$, 再合并两个 0.3 得 0.6, 最后 $0.4 + 0.6$ 。一种码长为 (1, 2, 3, 3), 平均码长 1.9 bits。熵约为 1.846 bits, 满足 $H \leq L < H + 1$ 。

I6. Y 均匀, 所以 $H(Y) = 1$; 给定 X 后只剩噪声, $H(Y|X) = h_2(q)$; 因此 $I(X; Y) = 1 - h_2(q)$ 。

I7. 用互信息链式法则:

$$I(X; Y, Z) = I(X; Y) + I(X; Z|Y) = I(X; Y),$$

同时

$$I(X; Y, Z) = I(X; Z) + I(X; Y|Z) \geq I(X; Z).$$

I8. 典型集约有 2^{nH} 个元素。码率 R 提供 2^{nR} 个索引。 $R > H$ 时足够覆盖高概率典型集; $R < H$ 时可编码的典型序列比例按 $2^{-n(H-R)}$ 衰减。

I9. 擦除位置以概率 ε 不提供信息, 容量为 $1 - \varepsilon$ 。BSC 容量为 $1 - h_2(\varepsilon)$; 擦除位置可见, 翻转位置不可见, 因此两者不能只按“受损比例”比较。

I10. 错误码字数约 2^{nR} , 单个伪匹配概率约 $2^{-n(I-\delta)}$, 乘积为

$$2^{-n(I-R-\delta)} = 2^{-n\delta}.$$

I11. 设原串为 X 、消息为 M 、恢复结果为 $\hat{X}$ 。Fano 给出 $H(X|M) = o(m)$, 于是

$$m = H(X) = I(X; M) + H(X|M) \leq H(M) + o(m) \leq s + o(m).$$

I12. 一种合格定义是: X 为真实频率向量, Z 为预测向量, 误差 $\eta = \|X - Z\|_1 / \|X\|_1$; 状态限于 s bits; 成功事件为所有查询误差满足给定界, 失败概率至多 δ 。实验只能说明选定分布上的经验表现, 不能单独声称 worst-case consistency/robustness。

参考文献

- [1] Thomas M. Cover and Joy A. Thomas. *Elements of Information Theory*, 2nd edition. Wiley, 2006.
- [2] David J. C. MacKay. *Information Theory, Inference, and Learning Algorithms*. Cambridge University Press, 2003.
- [3] Raymond W. Yeung. *A First Course in Information Theory*. Springer, 2002.
- [4] Graham Cormode and Ke Yi. *Small Summaries for Big Data*. Cambridge University Press, 2020.