

随机算法自学讲义

从概率界、经典算法到数据流 Sketch 与可验证搜索

RUCmonk2

2026 年 8 月

如何使用这本讲义

随机算法不是“跑几次看看”。一个完整分析必须同时说明随机源、成功事件、失败概率、时间/空间成本以及失败时的处理方式。本讲义以有限概率空间和离散算法为主，重点连接数据流 Sketch、随机验证器和 AI4TCS。

学习每个算法时固定填写：

输入与随机源	哪些选择是随机的，需要几阶独立或完全独立？
输出与成功事件	输出对象是什么，何时判定成功？
误差与概率	是单侧/双侧误差，失败概率怎样依赖参数？
资源	时间、空间、passes、communication 分别是多少？
失败处理	重复、取中位数、回退到确定性基线还是允许失败？

目录

如何使用这本讲义	1
第一章 概率工具与集中不等式	4
1.1 事件、指示变量与期望线性性	4
1.2 Union bound	5
1.3 Markov 与 Chebyshev 不等式	5
1.4 矩母函数与 Chernoff 方法	5
1.5 Hoeffding 不等式	6
1.6 概率放大	7
1.7 工具选择表	7
1.8 小结与验收	7
第二章 随机化范式与经典案例	8
2.1 Monte Carlo 与 Las Vegas	8
2.2 随机快速排序	8
2.3 Freivalds 矩阵乘积验证	9
2.4 Karger 随机收缩最小割	10
2.5 随机化改变了什么	10
2.6 小结与验收	11
第三章 抽样、哈希与随机置换	12
3.1 Bernoulli 抽样与无偏估计	12
3.2 Reservoir sampling	12
3.3 Fisher-Yates 随机置换	13
3.4 通用哈希与碰撞概率	13
3.4.1 线性二进制哈希	14
3.5 二阶独立够不够	14
3.6 随机性也是资源	14

3.7	小结与验收	15
第四章	数据流 Sketch: 频率、二阶矩与可合并性	16
4.1	数据流模型	16
4.2	Count-Min Sketch	16
4.3	Count Sketch	17
4.4	AMS 二阶矩估计	18
4.5	线性 Sketch 与可合并性	18
4.6	三种 Sketch 对照	19
4.7	实验应该怎样验收	19
4.8	小结与验收	19
第五章	概率方法、随机舍入与随机游走	21
5.1	概率方法	21
5.2	条件期望法	21
5.3	随机舍入	22
5.4	Markov 链基础	23
5.5	无向图随机游走	23
5.6	混合时间与 MCMC 边界	23
5.7	小结与验收	24
第六章	随机算法在 AI4TCS 中的验证与实验	25
6.1	四层 verifier	25
6.2	正确性分数和性能分数分开	25
6.3	数据划分与适应性过拟合	26
6.4	随机测试怎样报告	26
6.5	Freivalds 作为分层 verifier	26
6.6	Property testing 的位置	27
6.7	Lean、SMT、穷举和随机测试如何分工	27
6.8	两周最小闭环	27
6.9	发布前验收表	28
6.10	小结与验收	28
第七章	综合习题与参考答案	29
7.1	习题	29
7.2	参考答案与提示	29

第一章 概率工具与集中不等式

随机算法分析不是把“随机”留给实验，而是把随机选择写成随机变量，再用期望、方差和尾界控制失败事件。本章建立后续反复使用的工具箱。

1.1 事件、指示变量与期望线性性

对事件 A ，定义指示变量

$$\mathbf{1}_A = \begin{cases} 1, & A \text{ 发生}, \\ 0, & A \text{ 不发生}. \end{cases}$$

它满足 $\mathbb{E}[\mathbf{1}_A] = \mathbb{P}(A)$ 。计数型随机变量常可写成指示变量之和，从而利用

$$\mathbb{E}\left[\sum_i X_i\right] = \sum_i \mathbb{E}[X_i].$$

期望线性性不要求 X_i 独立。

例 1.1 (空桶数). 把 n 个球独立均匀放入 n 个桶。令 I_j 表示第 j 个桶为空，则

$$\mathbb{P}(I_j = 1) = \left(1 - \frac{1}{n}\right)^n.$$

空桶总数 $X = \sum_{j=1}^n I_j$ ，所以

$$\mathbb{E}X = n \left(1 - \frac{1}{n}\right)^n \approx \frac{n}{e}.$$

各桶是否为空并不独立，但不影响期望计算。

1.2 Union bound

定理 1.2 (Union bound). 对任意事件 $E_1, \dots, E_m$,

$$\mathbb{P}\left(\bigcup_{i=1}^m E_i\right) \leq \sum_{i=1}^m \mathbb{P}(E_i).$$

它不要求事件独立。代价是可能重复计算交叠部分，因此界可能较松。算法中常把“存在某一步失败”分解成多个局部失败事件，再控制总失败概率。

例 1.3 (对所有查询同时成功). 若单个查询失败概率至多 δ/q ，则对预先固定的 q 个查询，至少一个失败的概率至多 δ 。若查询是根据前面结果自适应选择的，还需检查单查询保证是否在条件分布下仍成立，不能机械套用。

1.3 Markov 与 Chebyshev 不等式

定理 1.4 (Markov 不等式). 若 $X \geq 0$ 且 $a > 0$ ，则

$$\mathbb{P}[X \geq a] \leq \frac{\mathbb{E}X}{a}.$$

证明. 点态上有 $X \geq a \mathbf{1}_{\{X \geq a\}}$ 。两边取期望：

$$\mathbb{E}X \geq a\mathbb{P}[X \geq a].$$

□

定理 1.5 (Chebyshev 不等式). 若 X 方差有限，则对 $t > 0$ ，

$$\mathbb{P}[|X - \mathbb{E}X| \geq t] \leq \frac{\text{Var}(X)}{t^2}.$$

证明. 对非负随机变量 $(X - \mathbb{E}X)^2$ 使用 Markov 不等式，阈值取 t^2 。

□

Markov 只使用均值，Chebyshev 使用到二阶矩。它们假设少、适用广，但通常只给多项式衰减。

1.4 矩母函数与 Chernoff 方法

对任意 $\lambda > 0$ ，指数函数单调，故

$$\begin{aligned} \mathbb{P}[X \geq a] &= \mathbb{P}[e^{\lambda X} \geq e^{\lambda a}] \\ &\leq e^{-\lambda a} \mathbb{E}[e^{\lambda X}]. \end{aligned}$$

随后选择最优 λ 。若 $X = \sum_i X_i$ 且 X_i 独立，则

$$\mathbb{E}[e^{\lambda X}] = \prod_i \mathbb{E}[e^{\lambda X_i}],$$

这正是独立性带来指数尾界的关键位置。

定理 1.6 (Bernoulli 和的 Chernoff 界). 设 $X_i \in \{0, 1\}$ 相互独立, $X = \sum_i X_i$, $\mu = \mathbb{E}X$ 。则对 $\delta > 0$,

$$\mathbb{P}[X \geq (1 + \delta)\mu] \leq \left(\frac{e^\delta}{(1 + \delta)^{1+\delta}} \right)^\mu.$$

特别地, 对 $0 < \delta \leq 1$,

$$\mathbb{P}[X \geq (1 + \delta)\mu] \leq e^{-\mu\delta^2/3},$$

并且

$$\mathbb{P}[X \leq (1 - \delta)\mu] \leq e^{-\mu\delta^2/2}.$$

上尾证明骨架. 对 Bernoulli 变量,

$$\mathbb{E}[e^{\lambda X_i}] = 1 - p_i + p_i e^\lambda \leq \exp(p_i(e^\lambda - 1)).$$

独立性给出

$$\mathbb{E}[e^{\lambda X}] \leq \exp(\mu(e^\lambda - 1)).$$

代入 Markov 型界并令 $e^\lambda = 1 + \delta$, 得到第一条。再用 $(1 + \delta) \ln(1 + \delta) - \delta \geq \delta^2/3$ ($0 < \delta \leq 1$) 得到简化形式。□

容易混淆

Chernoff 界不是“任何随机变量都指数集中”。标准版本需要独立 Bernoulli 或相应负相关条件。若算法反复复用同一随机哈希, 变量可能相关, 必须重新检查假设。

1.5 Hoeffding 不等式

定理 1.7 (Hoeffding). 若独立随机变量 $X_i \in [a_i, b_i]$, 令 $S = \sum_i X_i$, 则

$$\mathbb{P}[S - \mathbb{E}S \geq t] \leq \exp\left(-\frac{2t^2}{\sum_i (b_i - a_i)^2}\right).$$

双侧界多一个因子 2。

对 n 个 $[0, 1]$ 样本的均值 $\bar{X}$,

$$\mathbb{P}[|\bar{X} - \mathbb{E}X| \geq \epsilon] \leq 2e^{-2n\epsilon^2}.$$

要使失败概率至多 δ ，充分取

$$n \geq \frac{1}{2\epsilon^2} \ln \frac{2}{\delta}.$$

1.6 概率放大

若一次 Monte Carlo 判定以概率至少 $2/3$ 正确，独立运行 k 次并取多数票，错误概率由 Chernoff 界降到 $e^{-\Theta(k)}$ 。因此要达到错误概率 δ ，通常只需 $k = O(\log(1/\delta))$ 次。

对估计问题，常使用 median trick：每组先产生常数成功概率的估计，再对多组独立估计取中位数。只要超过半数组合格，中位数就合格。

直觉

随机算法中常把任务拆成两层：先构造一个常数成功概率、容易分析的基本估计器；再用独立重复把可靠性提升到用户指定的 $1 - \delta$ 。

1.7 工具选择表

工具	所需信息	典型尾部	常见用途
Union bound	单个事件概率	概率相加	多个失败事件
Markov	非负、均值	$1/a$	粗略单侧界
Chebyshev	均值、方差	$1/t^2$	无强独立假设估计
Chernoff	独立 Bernoulli 和	指数衰减	计数、采样、放大
Hoeffding	独立有界变量	指数衰减	样本均值

1.8 小结与验收

本节验收

1. 用指示变量重新推导空桶数期望；
2. 从 Markov 推导 Chebyshev；
3. 在 Chernoff 证明中圈出使用独立性的那一步；
4. 推导估计 Bernoulli 均值到加性误差 ϵ 、失败概率 δ 所需的样本量；
5. 解释为什么重复实验必须使用独立随机性才能直接应用多数票放大。

第二章 随机化范式与经典案例

2.1 Monte Carlo 与 Las Vegas

定义 2.1 (Monte Carlo 算法). 运行时间有确定上界或高概率上界, 但输出允许以小概率错误。通常通过独立重复降低错误概率。

定义 2.2 (Las Vegas 算法). 只要终止, 输出总是正确; 运行时间是随机变量, 通常分析其期望或尾部。

二者可以互相转换一部分: 若 Monte Carlo 输出可被确定性 verifier 检查, 就可以反复生成直到通过, 得到 Las Vegas 过程; 但若 verifier 只能发现部分错误, 这个转换不成立。

类型	正确性	主要随机量
Monte Carlo	允许小概率错误	输出是否正确
Las Vegas	输出始终正确	运行时间/重试次数

2.2 随机快速排序

随机快速排序从当前子数组中均匀选择 pivot, 再递归排序两侧。无论 pivot 如何选择, 最终结果都正确, 因此它是 Las Vegas 算法; 随机性只影响比较次数。

设输入元素互异, 排序后为 $z_1 < \dots < z_n$ 。令 X_{ij} 表示 z_i, z_j 是否被直接比较。两者会比较, 当且仅当集合

$$\{z_i, z_{i+1}, \dots, z_j\}$$

中第一个被选为 pivot 的元素是 z_i 或 z_j , 所以

$$\mathbb{P}[X_{ij} = 1] = \frac{2}{j - i + 1}.$$

总比较次数 $X = \sum_{i < j} X_{ij}$, 由期望线性性

$$\begin{aligned}\mathbb{E}X &= \sum_{i < j} \frac{2}{j-i+1} \\ &= 2 \sum_{k=2}^n \frac{n-k+1}{k} \\ &= 2(n+1)H_n - 4n = O(n \log n).\end{aligned}$$

直觉

分析没有追踪递归树的所有相关性, 而是改问每一对元素是否比较。指示变量让复杂的全局过程变成可加的局部事件。

2.3 Freivalds 矩阵乘积验证

给定 $n \times n$ 矩阵 A, B, C , 要验证 $AB = C$ 。直接计算矩阵乘积需要 $O(n^3)$ 标准算术操作。Freivalds 算法随机取 $r \in \{0, 1\}^n$, 检查

$$A(Br) = Cr.$$

矩阵向量乘法只需 $O(n^2)$ 。

```
def freivalds(A, B, C, trials):
    for _ in range(trials):
        r = random_bit_vector(n)
        if A @ (B @ r) != C @ r:
            return False
    return True
```

若 $AB = C$, 检查必然通过, 所以没有 false negative。若 $D = AB - C \neq 0$, 至少有一行向量 $d \neq 0$ 。取 d 的某个非零坐标 j ; 固定 r 的其他坐标后, 方程 $d^T r = 0$ 对 $r_j \in \{0, 1\}$ 至多有一个选择成立, 因此

$$\mathbb{P}[Dr = 0] \leq \frac{1}{2}.$$

独立重复 k 次, 错误接受概率至多 2^{-k} 。

容易混淆

结论依赖运算所在的环/域和等号检查方式。浮点矩阵的近似相等需要单独定义容差与数值稳定性, 不能直接照搬精确代数证明。

与 AI4TCS / Lean 的连接

Freivalds 算法是 verifier-guided algorithm discovery 的理想入门案例：候选 C 可由模型或程序生成，随机 verifier 快速拒绝错误候选，最终高价值候选再做精确计算或形式证明。随机检查降低成本，但没有取代最终证书。

2.4 Karger 随机收缩最小割

对无向多重图，重复随机选择一条边并收缩其两个端点，删除自环但保留平行边，直到只剩两个超级节点；跨越两节点的边即为候选割。

固定一个大小为 k 的最小割。只要尚未收缩这条割上的边，它就仍然存在。若当前有 r 个超级节点，因为每个节点度至少为 k ，边数至少为 $rk/2$ 。随机边落在固定最小割上的概率至多

$$\frac{k}{rk/2} = \frac{2}{r}.$$

因此从 n 个节点一路保护该最小割到 2 个节点的概率至少

$$\begin{aligned} \prod_{r=3}^n \left(1 - \frac{2}{r}\right) &= \prod_{r=3}^n \frac{r-2}{r} \\ &= \frac{2}{n(n-1)}. \end{aligned}$$

单次成功率虽低，但独立重复 T 次后，全失败概率至多

$$\left(1 - \frac{2}{n(n-1)}\right)^T \leq \exp\left(-\frac{2T}{n(n-1)}\right).$$

取 $T = \Theta(n^2 \log(1/\delta))$ 可把失败概率降到 δ 。

2.5 随机化改变了什么

三个案例分别体现不同作用：

- 快速排序：随机化避免固定输入触发总是糟糕的 pivot，输出仍确定正确；
- Freivalds：随机化把昂贵精确验证换成快速单侧错误验证；
- Karger：随机化在巨大组合空间中采样一个结构，靠重复提高找到最优解的概率。

分析时必须明确随机性来自输入分布还是算法内部。随机快速排序的期望界对任意固定输入成立，随机性来自 pivot；这与假设输入本身随机排列是不同模型。

2.6 小结与验收

本节验收

1. 判断随机快速排序属于 Monte Carlo 还是 Las Vegas，并说明原因；
2. 推导一对排序后相距 $k - 1$ 的元素被比较的概率；
3. 写出 Freivalds 的单侧错误事件并推导 k 次后的错误概率；
4. 推导 Karger 算法中当前有 r 个超级节点时误收缩固定最小割的概率上界；
5. 对三个案例分别写出随机源、成功事件、资源和放大方式。

第三章 抽样、哈希与随机置换

随机算法经常需要从大对象中保留一个小而无偏的代表，或把对象随机映射到较小空间。本章重点不是 API，而是证明每种随机操作保留了什么分布性质。

3.1 Bernoulli 抽样与无偏估计

设数值 $a_1, \dots, a_n$ 固定，独立生成 $I_i \sim \text{Bernoulli}(p)$ 。估计总和

$$T = \sum_{i=1}^n a_i$$

的一种 Horvitz-Thompson 型估计为

$$\hat{T} = \sum_{i=1}^n \frac{I_i a_i}{p}.$$

因为 $\mathbb{E}I_i = p$,

$$\mathbb{E}\hat{T} = T.$$

若抽样独立，则

$$\text{Var}(\hat{T}) = \sum_i \frac{a_i^2}{p^2} \text{Var}(I_i) = \frac{1-p}{p} \sum_i a_i^2.$$

这同时说明：无偏不代表方差小；当 p 很小或数值极不均衡时，估计可能剧烈波动。

3.2 Reservoir sampling

数据流长度未知时，要均匀保留一个元素：

1. 第 1 个元素直接放入 reservoir；
2. 看到第 t 个元素时，以概率 $1/t$ 用它替换当前元素；
3. 否则保持不变。

定理 3.1. 处理完前 t 个元素后，每个元素留在 *reservoir* 中的概率都为 $1/t$ 。

证明. 第 t 个元素以概率 $1/t$ 被选中。对旧元素 $i < t$, 由归纳假设它在第 $t-1$ 步后保留的概率为 $1/(t-1)$; 第 t 步不被替换的概率为 $1 - 1/t$, 所以

$$\frac{1}{t-1} \left(1 - \frac{1}{t}\right) = \frac{1}{t}.$$

□

大小为 k 的 reservoir 类似: 前 k 个全部保留; 第 $t > k$ 个元素以概率 k/t 进入, 并均匀替换一个槽位。最终每个元素被包含的概率为 k/t , 但槽位事件之间并不独立。

3.3 Fisher–Yates 随机置换

要均匀生成长度 n 的随机排列, 从 $i = n-1$ 到 1 , 在 $\{0, \dots, i\}$ 中均匀选择 j , 交换位置 i, j 。

```
def fisher_yates(a, rng):
    for i in range(len(a) - 1, 0, -1):
        j = rng.randint(0, i)
        a[i], a[j] = a[j], a[i]
```

每个排列对应唯一一串选择

$$j_{n-1} \in \{0, \dots, n-1\}, \dots, j_1 \in \{0, 1\}.$$

该选择串的概率为

$$\frac{1}{n} \cdot \frac{1}{n-1} \cdots \frac{1}{2} = \frac{1}{n!},$$

因此输出严格均匀。

容易混淆

“对每个位置随机交换一个全局随机位置”的朴素 shuffle 一般不均匀。验证随机生成器时, 要证明每个对象的输出概率, 而不是只看几次样例像不像随机。

3.4 通用哈希与碰撞概率

定义 3.2 (通用哈希族). 从宇宙 U 映射到 $[m]$ 的哈希族 $\mathcal{H}$ 称为通用的, 如果对任意 $x \neq y$,

$$\mathbb{P}_{h \sim \mathcal{H}}[h(x) = h(y)] \leq \frac{1}{m}.$$

这个概率针对随机选择的哈希函数, 而不是假设输入随机。它允许对任意固定输入集合做碰撞期望分析。

3.4.1 线性二进制哈希

把 key 写成 u 位向量 $x \in \mathbb{F}_2^u$ 。随机选择矩阵 $A \in \mathbb{F}_2^{b \times u}$ ，定义

$$h_A(x) = Ax \in \mathbb{F}_2^b.$$

对 $x \neq y$ ，令 $v = x - y \neq 0$ 。每一行随机向量与 v 的内积为均匀比特，各行独立，因此

$$\mathbb{P}[h_A(x) = h_A(y)] = \mathbb{P}[Av = 0] = 2^{-b}.$$

输出桶数 $m = 2^b$ ，碰撞概率恰为 $1/m$ 。

3.5 二阶独立够不够

若随机变量族中任意两个独立，称为 pairwise independent。它通常足以控制：

- 碰撞数的期望；
- 线性估计器的方差；
- 通过 Chebyshev 得到的常数概率保证。

但 Chernoff 的标准指数尾界通常需要完全独立或更强的有限阶独立。算法实现中使用短 seed 生成哈希时，必须把“理论需要几阶独立”写进配置。

3.6 随机性也是资源

若每次试验需要选择 $h \in \mathcal{H}$ ，存储完整随机函数可能比算法状态还大。实际会使用参数化哈希族，只存 seed。分析应报告：

- seed 长度和哈希计算时间；
- seed 是公开还是私有；
- 多次重复是否真正独立；
- 输入是否可在看到 seed 后自适应选择。

对 oblivious adversary 成立的 sketch，在 adaptive adversary 下可能失效；这不是实现细节，而是问题模型的一部分。

3.7 小结与验收

本节验收

1. 推导 Bernoulli 抽样总和估计器的无偏性和方差；
2. 用归纳法证明 reservoir sampling 的均匀性；
3. 解释 Fisher-Yates 为什么一一对应 $n!$ 条随机选择路径；
4. 证明线性二进制哈希的碰撞概率为 2^{-b} ；
5. 给出一个只需 pairwise independence 和一个需要更强独立性的分析。

第四章 数据流 Sketch：频率、二阶矩与可合并性

4.1 数据流模型

频率向量 $f \in \mathbb{R}^N$ 隐式地由更新流定义。更新 (i, Δ) 表示

$$f_i \leftarrow f_i + \Delta.$$

常见模型包括：

insertion-only $\Delta \geq 0$;

strict turnstile 允许负更新，但任意时刻 $f_i \geq 0$;

general turnstile 中间和最终频率都可为负。

算法保证必须注明模型。例如 Count-Min 的单侧上估计依赖非负频率。

统一接口为：初始化、更新、查询、合并。随机 seed、哈希独立性、空间、更新时间和失败概率都属于协议的一部分。

4.2 Count-Min Sketch

选择 d 个相互独立的通用哈希函数 $h_j : [N] \rightarrow [w]$ ，维护 $d \times w$ 非负计数表。更新 (i, Δ) 时，对每行执行

$$C_{j, h_j(i)} \leftarrow C_{j, h_j(i)} + \Delta.$$

点查询返回

$$\hat{f}_i = \min_{j \in [d]} C_{j, h_j(i)}.$$

在 insertion-only 模型中，每个桶包含目标频率和碰撞噪声，因此始终有

$$\hat{f}_i \geq f_i.$$

固定一行，定义碰撞噪声

$$Z_j = \sum_{k \neq i: h_j(k)=h_j(i)} f_k.$$

由通用哈希，

$$\mathbb{E}Z_j \leq \frac{\|f\|_1 - f_i}{w} \leq \frac{\|f\|_1}{w}.$$

取 $w = \lceil e/\epsilon \rceil$ ，Markov 不等式给出

$$\mathbb{P}[Z_j \geq \epsilon \|f\|_1] \leq \frac{1}{e}.$$

若 d 行独立且查询取最小值，则所有行都坏的概率至多 e^{-d} 。取

$$d = \left\lceil \ln \frac{1}{\delta} \right\rceil$$

可得：

$$\mathbb{P} \left[f_i \leq \hat{f}_i \leq f_i + \epsilon \|f\|_1 \right] \geq 1 - \delta.$$

空间为 $O(\epsilon^{-1} \log(1/\delta))$ 个计数器，更新时间为 $O(\log(1/\delta))$ 。

容易混淆

这是对一个预先固定查询 i 的保证。若要同时保证大量 key，需 union bound 或更强结构；若查询根据 sketch 输出自适应选择，还要重新分析。

4.3 Count Sketch

Count Sketch 每行使用桶哈希 $h_j : [N] \rightarrow [w]$ 和独立符号哈希 $s_j : [N] \rightarrow \{-1, +1\}$ 。更新时

$$C_{j,h_j(i)} \leftarrow C_{j,h_j(i)} + s_j(i)\Delta.$$

第 j 行对 f_i 的估计为

$$X_j = s_j(i)C_{j,h_j(i)}.$$

展开：

$$X_j = f_i + \sum_{k \neq i: h_j(k)=h_j(i)} s_j(i)s_j(k)f_k.$$

随机符号使碰撞噪声均值为 0，因此 $\mathbb{E}X_j = f_i$ 。在适当独立性下，

$$\text{Var}(X_j) \leq \frac{\|f_{-i}\|_2^2}{w},$$

其中 f_{-i} 表示去掉第 i 个坐标。取足够宽度后, Chebyshev 给出常数成功概率; 多行取中位数把失败概率降为 δ 。

Count-Min 的噪声只有正方向, 适合非负频率的单侧上界; Count Sketch 用随机符号抵消噪声, 可处理 turnstile 更新和双侧误差。

4.4 AMS 二阶矩估计

目标是估计

$$F_2 = \sum_{i=1}^N f_i^2 = \|f\|_2^2.$$

选取 4-wise independent 符号 $s(i) \in \{-1, +1\}$, 维护线性投影

$$Z = \sum_i s(i) f_i.$$

每次更新 (i, Δ) 时只需执行 $Z \leftarrow Z + s(i)\Delta$ 。输出 $X = Z^2$ 。

由符号均值为 0、两两独立, 交叉项期望消失:

$$\mathbb{E}X = \mathbb{E} \left(\sum_i s(i) f_i \right)^2 = \sum_i f_i^2 = F_2.$$

利用 4-wise independence 展开四阶矩, 可得

$$\mathbb{E}[Z^4] = \sum_i f_i^4 + 6 \sum_{i < j} f_i^2 f_j^2 \leq 3F_2^2,$$

所以

$$\text{Var}(X) = \mathbb{E}[Z^4] - F_2^2 \leq 2F_2^2.$$

独立平均 $O(1/\epsilon^2)$ 个副本得到常数概率相对误差, 再用多组中位数把失败概率降为 δ 。

4.5 线性 Sketch 与可合并性

若 sketch 可写成

$$S(f) = Af$$

, 其中 A 由随机 seed 固定, 则

$$S(f + g) = S(f) + S(g).$$

因此不同分片只要使用相同随机矩阵/哈希 seed, 就可以直接合并摘要。Count-Min 的计数表、Count Sketch 和 AMS 投影都具有相应线性结构。

容易混淆

“数组形状相同”不等于可合并。若两个 sketch 使用不同 seed，逐项相加通常没有原保证；合并协议必须把随机参数视作摘要元数据。

4.6 三种 Sketch 对照

方法	目标	核心随机性	典型误差口径
Count-Min	点频率	桶碰撞	单侧 $\epsilon \ f\ _1$
Count Sketch	点频率/重频项	桶 + 随机符号	双侧 ℓ_2 噪声
AMS	F_2	随机符号投影	相对误差

4.7 实验应该怎样验收

固定同一输入流，至少记录：

- exact baseline；
- seed、宽度、深度和哈希族；
- 平均、最大、95% 分位误差；
- 理论阈值被违反的次数；
- 两段分别更新再 merge 与整段直接更新的差异；
- insertion-only、strict/general turnstile 模型是否一致。

与 AI4TCS / Lean 的连接

学习增强 Sketch 的第一步不是训练预测器，而是保持这里的经典接口与保证不变，再明确预测器提供什么 side information、预测误差如何定义、准确时收益和任意错误时回退分别是什么。

4.8 小结与验收

本节验收

1. 推导 Count-Min 一行碰撞噪声的期望；
2. 说明“取最小值”如何把单行常数失败概率放大；
3. 解释 Count Sketch 的随机符号为何让噪声均值为 0；

4. 从 $Z = \sum_i s(i)f_i$ 推导 AMS 估计的无偏性;
5. 写出 mergeability 对 seed 和线性更新的要求。

第五章 概率方法、随机舍人与随机游走

本章展示随机性除“直接运行算法”外的三种作用：证明某个组合对象必然存在、把连续解转成离散解、在状态空间上采样。

5.1 概率方法

概率方法的基本逻辑是：若随机生成对象满足性质 P 的概率大于 0，那么至少存在一个确定对象满足 P 。证明可以完全非构造，也可以进一步导出随机算法或确定性算法。

例 5.1 (Max-Cut 的 $m/2$ 保证). 对无向图的每个顶点独立抛公平硬币，决定放入割的左侧或右侧。每条边跨越割的概率为 $1/2$ 。若 X 是跨割边数，由期望线性性

$$\mathbb{E}X = \frac{m}{2}.$$

因此至少存在一个割包含不少于 $m/2$ 条边；否则所有割都少于 $m/2$ ，平均值也会小于 $m/2$ 。

例 5.2 (随机赋值满足 3-CNF 子句). 若一个子句包含三个互异文字，随机独立赋值使它不满足的概率为 $1/8$ ，满足概率为 $7/8$ 。因此对 m 个这类子句，满足子句数的期望为 $7m/8$ ，必存在至少满足该数量的赋值。

5.2 条件期望法

概率方法常可去随机化。若目标随机变量为 X ，逐个固定随机选择，并总是选择使条件期望不下降的分支：

$$\mathbb{E}[X|R_1 = r_1, \dots, R_t = r_t] \geq \mathbb{E}[X|R_1 = r_1, \dots, R_{t-1} = r_{t-1}].$$

因为父节点条件期望是各分支条件期望的加权平均，至少一个分支不低于父节点。全部固定后，实际目标值不低于初始期望。

对 Max-Cut，可以逐个决定顶点放哪侧，计算尚未决定边的条件期望，得到确定性 $m/2$ 保证。

直觉

“随机解的期望很好”并不意味着必须真的抛硬币。若条件期望能高效计算，就可以沿着不降低期望的分支确定性地走到一个好解。

5.3 随机舍入

组合优化常先求线性规划松弛，再把分数解随机转成 0/1 解。设集合覆盖实例中，元素宇宙有 n 个元素，集合 S_j 成本为 c_j ，LP 解满足

$$\sum_{j:e \in S_j} x_j \geq 1, \quad 0 \leq x_j \leq 1.$$

令 $\alpha = \ln n + 1$ ，独立选择集合 S_j 的概率为

$$p_j = \min\{1, \alpha x_j\}.$$

期望成本满足

$$\mathbb{E}[\text{cost}] = \sum_j c_j p_j \leq \alpha \sum_j c_j x_j.$$

对任意元素 e ，若没有某个 $p_j = 1$ 的覆盖集合，则它未被覆盖的概率

$$\begin{aligned} \mathbb{P}[e \text{ 未覆盖}] &= \prod_{j:e \in S_j} (1 - p_j) \\ &\leq \exp \left(- \sum_{j:e \in S_j} p_j \right) \\ &\leq e^{-\alpha} < \frac{1}{n}. \end{aligned}$$

再用 union bound 控制存在未覆盖元素的概率。实际算法可以重试，或对少量未覆盖元素做确定性修补。

容易混淆

随机舍入的独立选择、LP 约束、缩放因子和修补步骤都是保证的一部分。只写“按 x_j 当概率采样”通常不足以得到可行解或高概率界。

5.4 Markov 链基础

有限状态 Markov 链由转移矩阵 P 定义：

$$P(x, y) = \mathbb{P}[X_{t+1} = y | X_t = x], \quad \sum_y P(x, y) = 1.$$

Markov 性表示给定当前状态后，下一步与更早历史条件独立。

定义 5.3 (平稳分布). 分布 π 若满足

$$\pi(y) = \sum_x \pi(x) P(x, y), \quad \text{即} \quad \pi = \pi P,$$

则称为平稳分布。

若链不可约且非周期，则从任意初始分布出发会收敛到唯一平稳分布。实际常加入“以概率 $1/2$ 原地不动”的 lazy 步骤消除二分图随机游走的周期性。

5.5 无向图随机游走

在无向图 $G = (V, E)$ 上，从顶点 u 均匀走到邻居：

$$P(u, v) = \begin{cases} 1/\deg(u), & (u, v) \in E, \\ 0, & \text{否则}. \end{cases}$$

若图连通，候选平稳分布为

$$\pi(v) = \frac{\deg(v)}{2|E|}.$$

验证 detailed balance：对边 (u, v) ,

$$\pi(u)P(u, v) = \frac{1}{2|E|} = \pi(v)P(v, u).$$

对所有 u 求和即得 $\pi P = \pi$ 。

这说明普通随机游走更常访问高度顶点，不是对顶点均匀采样。若研究需要均匀分布，必须修改转移规则，例如使用 Metropolis–Hastings 校正。

5.6 混合时间与 MCMC 边界

总变差距离为

$$\|\mu - \pi\|_{\text{TV}} = \frac{1}{2} \sum_x |\mu(x) - \pi(x)|.$$

混合时间 $t_{\text{mix}}(\epsilon)$ 是从最坏初态出发，使分布距离平稳分布至多 ϵ 所需的最小步数。

MCMC 用容易模拟的 Markov 链近似从复杂分布采样。仅验证平稳分布还不够：链可能混合极慢，有限步样本仍强烈依赖初始状态。实验必须记录 burn-in、链长度、自相关和多链诊断，并且不能用“轨迹看起来稳定”替代理论混合界。

5.7 小结与验收

本节验收

1. 用期望线性性证明存在大小至少 $m/2$ 的割；
2. 说明条件期望法为什么每一步总能选到不变差的分支；
3. 在集合覆盖随机舍入中推导单个元素未覆盖概率；
4. 验证无向图随机游走的平稳分布；
5. 给出一个“平稳分布正确但有限步采样仍不可信”的原因。

第六章 随机算法在 AI4TCS 中的验证与实验

AI4TCS 中常见闭环是生成候选算法或程序、执行 verifier、把错误或分数反馈给搜索。随机化可以降低测试和搜索成本，但也引入统计波动、数据泄漏和适应性风险。

6.1 四层 verifier

1. **语法/接口层**：能否解析、编译，输入输出类型是否正确；
2. **小规模正确性层**：穷举有限输入，找到最小反例；
3. **随机测试层**：从明确定义的分布采样，估计失败率；
4. **理论/证书层**：不变量、形式证明、SMT 证书、复杂度和概率保证。

不同层回答不同问题。随机测试通过不能推出任意输入正确；形式证明通过也只保证当前 formal statement，不自动保证自然语言规范忠实。

6.2 正确性分数和性能分数分开

候选程序常同时有两个目标：

$$\begin{aligned} S_{\text{correct}} &= \text{通过的规范测试或证明义务,} \\ S_{\text{perf}} &= \text{运行时间、空间或目标函数.} \end{aligned}$$

必须先规定 correctness gate，再比较性能。否则搜索器可能通过返回常量、利用未覆盖边界或超时逃逸来获得高分。

一个稳健 evaluator 至少记录：

- 第一个失败输入和最小化后的反例；
- 超时、异常、数值溢出和非法输出；
- 随机 seed 与环境版本；

- 正确性与性能各自的聚合规则；
- 是否使用了隐藏测试和跨规模测试。

6.3 数据划分与适应性过拟合

把输入分为：搜索/训练集、validation、hidden tests 和 out-of-distribution tests。候选反复看到同一 verifier 反馈后，会对 verifier 本身过拟合；即使生成器不是神经网络，这种适应性仍存在。

风险包括：

- 记住有限输入答案；
- 针对固定随机 seed；
- 利用计时器、异常处理或浮点容差；
- 在训练规模内正确但跨规模失败；
- 产生语法不同、语义相同的大量重复候选。

因此 hidden tests 不能参与候选选择；最终还要用穷举、证明或新的随机性复核。

6.4 随机测试怎样报告

假设在 N 个独立测试中观察到 K 次失败。报告 K/N 只是点估计，还应给出置信区间或至少说明样本量与采样分布。

若观察到 0 次失败，不能说失败概率为 0。粗略的“rule of three”指出，在 95% 置信水平下，失败概率上界约为 $3/N$ （大样本近似）。要声称失败概率小于 10^{-6} ，几十个测试远远不够。

多个候选、多个指标和多轮搜索会产生 multiple testing 问题。只报告所有运行中的最好一次会严重高估性能；应固定预算并报告分布、均值/中位数与方差。

6.5 Freivalds 作为分层 verifier

验证模型生成的矩阵乘积候选 C 时，可以分层：

1. shape、dtype 和有限值检查；
2. 小矩阵精确乘法；
3. 大矩阵上运行 k 次 Freivalds，错误接受概率至多 2^{-k} ；
4. 对最终候选做精确验证或符号恒等式检查；

5. 若声称新算法，再检查乘法次数、加法次数、数值稳定性和等价变换。

这里随机 verifier 是筛选器，不是原创性或复杂度 verifier。

6.6 Property testing 的位置

Property testing 允许以少量查询区分：对象满足性质，还是与所有满足性质的对象至少相距 ϵ 。它通常不负责精确重建对象。

一个 property tester 必须写清：

- 距离度量；
- completeness 与 soundness；
- 查询模型和查询复杂度；
- 单侧或双侧错误；
- 输入是否可自适应响应查询。

把普通随机单元测试称为 property testing，若没有这些形式要素，会混淆证据等级。

6.7 Lean、SMT、穷举和随机测试如何分工

工具	适合验证	主要边界
穷举	极小有限域上的全覆盖	规模爆炸
随机测试	快速发现常见/分布性错误	不能证明无反例
SMT/SAT	有限逻辑、位向量、约束	建模和规模限制
Lean	明确定义下的可审计证明	形式化成本、语义忠实
概率证明	随机算法的一般保证	假设必须与实现一致

推荐先用随机测试发现反例，再把稳定的定义和核心不变量送入 Lean；不要一开始形式化完整系统，也不要让测试结果冒充定理。

6.8 两周最小闭环

与 AI4TCS / Lean 的连接

选择一个 20–50 行候选函数接口：

1. 第 1–2 天：写规范、exact baseline 和小规模穷举；

2. 第 3–5 天：加入随机测试、seed 日志和反例缩减；

3. 第 6–8 天：实现最简单的候选变异/搜索器；

4. 第 9–10 天：冻结搜索，运行 hidden/OOD tests；
5. 第 11–12 天：分析第一个失败类别和等价候选；
6. 第 13–14 天：整理命令、结果表、理论边界和停止判断。

6.9 发布前验收表

- 随机源、seed 和独立性是否记录？
- 失败事件和概率是理论界还是经验估计？
- 搜索集、hidden、OOD 是否物理隔离？
- 是否保存最小反例，而不是只有总分？
- 是否检查跨规模、数值边界和超时？
- 是否区分正确性、性能、原创性和渐近复杂度？
- 最终候选是否有更强 verifier 或人工审计？

6.10 小结与验收

本节验收

1. 为一个候选算法写出四层 verifier；
2. 解释为什么固定 seed 和重复公开测试会造成过拟合；
3. 说明 100 次测试零失败为何不能证明失败概率为零；
4. 给出 Freivalds 之后仍需精确验证的原因；
5. 选择一个性质，分别写出随机测试、SMT 或 Lean 能验证到哪一层。

第七章 综合习题与参考答案

7.1 习题

- R1.** 把 n 个球独立放入 n 个桶，使用指示变量计算碰撞球对数的期望。
- R2.** 设 X 非负且 $\mathbb{E}X = 10$ 。分别用 Markov 界估计 $\mathbb{P}[X \geq 50]$ ；若另知 $\text{Var}(X) = 16$ ，用 Chebyshev 估计 $\mathbb{P}[|X - 10| \geq 40]$ 。
- R3.** 需要估计 Bernoulli 均值到加性误差 0.02，失败概率至多 0.01。用 Hoeffding 给出充分样本量。
- R4.** 推导随机快速排序中 z_i, z_j 被比较的概率，并由此说明期望比较次数为 $O(n \log n)$ 。
- R5.** Freivalds 算法独立运行多少次可把错误接受概率降到 10^{-9} 以下？
- R6.** 对 $n = 20$ 的图，Karger 单次保留某个固定最小割的概率下界是多少？要把针对该固定割的失败概率降到 0.01，给出重复次数上界。
- R7.** 证明大小为 1 的 reservoir sampling 在处理第 t 个元素后均匀保留每个历史元素。
- R8.** 对线性二进制哈希 $h_A(x) = Ax$ ，说明为什么 $x \neq y$ 时碰撞概率为 2^{-b} 。
- R9.** 设 Count-Min 使用 $w = \lceil e/\epsilon \rceil$ 。从碰撞噪声期望出发推导单行失败概率 $1/e$ 。
- R10.** 展开 AMS 估计 Z^2 ，说明为什么 2-wise independence 足以保证无偏，而控制方差需要 4-wise independence。
- R11.** 对一个三角形加一条悬挂边的无向图，写出普通随机游走的平稳分布，并解释为什么不是均匀分布。
- R12.** 设计一个候选矩阵乘法程序的四层 verifier，区分随机筛选、精确正确性、运行性能和原创性检查。

7.2 参考答案与提示

- R1.** 对每对球 $i < j$ ，令 I_{ij} 表示它们落入同一桶，概率为 $1/n$ 。碰撞球对总数 $X = \sum_{i < j} I_{ij}$ ，所以

$$\mathbb{E}X = \binom{n}{2} \frac{1}{n} = \frac{n-1}{2}.$$

R2. Markov 给出 $10/50 = 0.2$ 。Chebyshev 给出 $16/40^2 = 0.01$ 。后者使用更多分布信息，但事件也写成围绕均值的双侧偏差。

R3. Hoeffding 给出 $2e^{-2n(0.02)^2} \leq 0.01$ ，因此

$$n \geq \frac{\ln 200}{2(0.02)^2} \approx 6623.$$

取整数上整。

R4. 区间 $\{z_i, \dots, z_j\}$ 中第一个 pivot 必须是两个端点之一，概率为 $2/(j-i+1)$ 。对所有 $i < j$ 求和得到 $2(n+1)H_n - 4n$ 。

R5. 需要 $2^{-k} < 10^{-9}$ ，即 $k > 9 \log_2 10 \approx 29.9$ ，所以 $k = 30$ 足够。

R6. 单次下界为 $2/(20 \cdot 19) = 1/190$ 。重复 T 次全失败概率至多 $e^{-T/190}$ ；令其不超过 0.01，可取 $T \geq 190 \ln 100 \approx 875$ 。

R7. 新元素以 $1/t$ 进入；旧元素以 $1/(t-1)$ 留到上一步，再以 $1 - 1/t$ 不被替换，乘积同样为 $1/t$ 。

R8. 令 $v = x - y \neq 0$ 。随机矩阵每一行与 v 的内积是均匀比特； b 行同时为 0 的概率为 2^{-b} 。

R9. 一行噪声 Z 的期望至多 $\|f\|_1/w \leq \epsilon \|f\|_1/e$ 。Markov 给出

$$\mathbb{P}[Z \geq \epsilon \|f\|_1] \leq 1/e.$$

R10. 二次展开只出现 s_i 和 $s_i s_j$ ，两两独立使交叉项期望为 0。方差涉及 Z^4 ，需要控制四个符号的乘积，因此使用 4-wise independence。

R11. 三角形上与悬挂边相连的顶点度为 3，另外两个三角形顶点度为 2，悬挂顶点度为 1。总度数为 8，所以平稳概率分别为 $3/8, 2/8, 2/8, 1/8$ 。

R12. 接口层检查 shape/dtype；小规模层精确计算 AB ；大规模筛选运行多次 Freivalds；最终正确性层做精确或符号验证；性能单独报告时间/空间；原创性还需等价变换去重、文献检索和复杂度分析。

参考文献

- [1] Rajeev Motwani and Prabhakar Raghavan. *Randomized Algorithms*. Cambridge University Press, 1995.
- [2] Michael Mitzenmacher and Eli Upfal. *Probability and Computing*, 2nd edition. Cambridge University Press, 2017.
- [3] Devdatt Dubhashi and Alessandro Panconesi. *Concentration of Measure for the Analysis of Randomized Algorithms*. Cambridge University Press, 2009.
- [4] Graham Cormode and Ke Yi. *Small Summaries for Big Data*. Cambridge University Press, 2020.